



HUTECH

Đại học Công nghệ Tp.HCM

HỆ CƠ SỞ DỮ LIỆU NÂNG CAO

Phân tích mạng xã hội Facebook và xác định những người có ảnh hưởng trong một nhóm


HVTH: Nguyễn Ngọc Đình - 2440861001

Hà Anh Dũng - 2440861003

Nguyễn Minh Trung Nghĩa - 2441861021

GVHD: PGS. TS. Nguyễn Thị Thúy Loan

Quy trình thực nghiệm



NỘI DUNG THUYẾT TRÌNH

- 01** Web Crawler – Web Scraping và công cụ hỗ trợ
- 02** Giới thiệu về hệ cơ sở dữ liệu OrientDB
- 03** Công thức tính điểm và thuật toán Pagerank
- 04** Kết quả thực nghiệm và hướng phát triển


01

Web Crawler- Web Scraping và công cụ hỗ trợ

Web Crawler

- Là quá trình sử dụng chương trình tự động (crawler hoặc bot) để duyệt qua các trang web và thu thập dữ liệu.
- Thường bắt đầu từ một URL và di chuyển qua các liên kết để thu thập và lập chỉ mục nội dung từ nhiều trang.
- Thường được sử dụng để:
 - + Xây dựng công cụ tìm kiếm.
 - + Lập chỉ mục nội dung web để phân tích.


Web Crawler




Web Scrapping

- Là quá trình xuất thông tin từ các trang web.
- Tập trung chủ yếu vào việc lấy các thông tin cần thiết từ một hoặc nhiều trang web để lưu trữ và phân tích các dữ liệu đã thu thập được.

Web Scrapping



Selenium



Beautiful Soup

CÀI ĐẶT MÔI TRƯỜNG


LẤY DỮ LIỆU HTML

CHUYỂN ĐỔI HTML

TAGS

STRING

COMMENTS



DỮ LIỆU HTML
CÓ CẤU TRÚC



Scrapy



Selenium

BeautifulSoup



Web Scraping

02

Giới thiệu về OrientDB

Khái niệm OrientDB

- Là hệ thống quản lý cơ sở dữ liệu NoSQL được viết bằng ngôn ngữ Java.
- Theo hướng đa mô hình, đa dạng loại cơ sở dữ liệu và hướng đối tượng.
- Cú pháp truy vấn tương tự SQL nhưng có thêm cú pháp và chức năng riêng biệt để làm việc với nhiều loại mô hình dữ liệu.
- Bao gồm 2 phiên bản Community Edition và Enterprise Edition.

Công dụng chính

- Xây dựng dữ liệu trên các mô hình: đồ thị, tài liệu, khóa-giá trị, đối tượng.
- Mở rộng và phân tán dữ liệu.
- Quản lý các quan hệ phức tạp cho các nhu cầu sử dụng dữ liệu khác nhau.

Giao diện OrientDB Studio



BROWSE

SCHEMA

SECURITY

GRAPH

FUNCTIONS

DB

testdb (root)

Database Management

StructureConfigurationExport

Clusters are sets of records grouped by a mean. Any mean you want to assign. You can use a Cluster like a Table of the Relational DBMS world, namely to group records of the same type. Or you could want to group records by different logics. There are two kinds of clusters: **Physical** and **In-memory**. The first one is persistent, the second one is volatile.

ID	Name	Records	Conflict Strategy
26	_studio	3	
27	_studio_1	3	
28	_studio_2	3	
29	_studio_3	1	
30	_studio_4	1	
31	_studio_5	1	
32	_studio_6	1	
33	_studio_7	1	
42	comments	18	
43	comments_1	18	
44	comments_2	18	
45	comments_3	18	
46	comments_4	18	
47	comments_5	18	
48	comments_6	18	
49	comments_7	18	
3	default	0	
18	e	0	
19	e_1	0	
20	e_2	0	

Graph Editor ?

Nodes 11

Edges 18

▶

📄

+

✂

🗑

MORE ▾

```
1 MATCH {Class: Groups}-HasJoined-{Class: Users}-MadePost-{Class: Posts}-HasComment-{Class: Comments}-
2 RETURN $pathelements
```

● Posts

● Comments

● Users

● Groups

— HasComment

— MadeComment

— HasCommentedBy

— HasJoined

— MadePost

Graph Query

Vertex

Edge

Graph Query

Vertex

Edge

OrientDB Function

An SAP Company

BROWSE SCHEMA SECURITY GRAPH **FUNCTIONS** DB

Functions

Search also in code

ON

countUsers

SQL

sum

javascript

top10UsersByPosts

SQL

Functions Management

SAVE + NEW CLONE DELETE

Name

sum

Language

javascript

☐ Idempotent

+ PARAMETER

a

b

```
1 return parseInt(a) + parseInt(b);
```

sum()

EXECUTE

```
2 {
3   "@type": "d",
4   "@version": 0,
5   "@fieldTypes": "value=d",
6   "value": 7
7 }
```

OrientDB Function

01

```
1 CREATE FUNCTION top10UsersByPosts "SELECT author_id, COUNT(post_id) as totalPosts FROM Posts GROUP BY author_id ORDER BY totalPosts DESC LIMIT 10" LANGUAGE SQL
```

?

RUN

EXPLAIN

↗

```
CREATE FUNCTION top10UsersByPosts "SELECT author_id, COUNT(post_id) as
totalPosts
FROM Posts
GROUP BY author_id
ORDER BY totalPosts DESC LIMIT 10"
LANGUAGE SQL
```

02

Functions Management ?

SAVE

+ NEW

CLONE

DELETE

Name top10UsersByPosts Language sql ☐ Idempotent + PARAMETER

```
1 SELECT author_id, COUNT(post_id) as totalPosts FROM Posts GROUP BY author_id ORDER BY totalPosts DESC LIMIT 10
```

OrientDB Function

The screenshot shows the OrientDB web interface. At the top, a query editor contains the command `1 SELECT top10UsersByPosts()`. Below the editor, there are buttons for `RUN` and `EXPLAIN`. A search bar for history and a local storage size indicator (213.78 KB) are also visible. The command `SELECT top10UsersByPosts()` is entered in the command field. The results section, titled `PROPERTIES`, shows a single record with a long JSON string representing an array of user data. At the bottom, a status bar indicates the query was executed in 0.078 seconds, returned 1 record, and has a limit of 20. There are also buttons for `Table`, `Raw`, and `Explain`.

1 `SELECT top10UsersByPosts()`

Search in history Local Storage Size 213.78 KB

COMMAND

`SELECT top10UsersByPosts()`

PROPERTIES

`top10UsersByPosts()`

`[{"author_id":"thangchung","totalPosts":13}, {"author_id":"tam.hon.vo.tri","totalPosts":2}, {"author_id":"uttutduoi","totalPosts":2}, {"author_id":"100050746939468","totalPosts":1}, {"author_id":"Daria.Nguyen88","totalPosts":1}, {"author_id":"hadinh891","totalPosts":1}, {"author_id":"100030467220331","totalPosts":1}, {"author_id":"100088962127712","totalPosts":1}, {"author_id":"100073982401006","totalPosts":1}, {"author_id":"votrongdao","totalPosts":1}]`

10 25 50 100 1000 5000

Query executed in 0.078 sec. Returned 1 record(s). Limit: 20 (CHANGE IT)

Table Raw Explain

- Hỗ trợ truy vấn thông qua gọi hàm bằng ngôn ngữ Javascript hoặc SQL.
- Tránh phải lặp lại query quá nhiều lần bằng cách truyền tham số vào hàm.



Follow

Luca Garulli

@lgarulli

Founder, Investor, Developer. Invented the Multi-Model Database concept, created #OrientDB Open Source DBMS (bought by @SAP), now @Arcade_DB

📍 Miami, Florida 🔗 arcadedata.com 📅 Joined September 2009

03

Công thức tính điểm và thuật toán Pagerank

Bản ghi trong mỗi User

PROPERTIES										
author_id	total_posts	group_id	group_name	author_name	total_reactions_on_posts	total_comments_on_posts	total_comments_on_others_posts	total_reactions_on_others_posts	influence_score	pagerank_score
100010204905417	0	363657942789633	binhdanhocai	Súp Lơ	1251	6130	831	8445	-0.54913825	0.01690603755542864
100094265337812	0	363657942789633	binhdanhocai	Nhật Đăng	7843	3468	1534	5945	-0.64346975	0.01690603755542864
DLK1990	0	363657942789633	binhdanhocai	Kha DL	4352	1243	2269	7580	-0.0028261922	0.01690603755542864
cuongnc1734	0	363657942789633	binhdanhocai	Cường NC	7750	9816	6298	4412	-0.50139487	0.01690603755542864
hoangvuvd18	0	363657942789633	binhdanhocai	Hoàng Vũ	1093	1448	9162	3081	-0.06564137	0.01690603755542864
long.awesome	0	363657942789633	binhdanhocai	Long Nguyễn	5887	2846	2265	7644	0.3831698	0.01690603755542864
phamhungtienbg	0	363657942789633	binhdanhocai	Phạm Tiến	8443	4376	4826	6280	-0.32984096	0.01690603755542864
thanhthegod	0	363657942789633	binhdanhocai	Thanh Nguyen Van	2923	3617	3470	5773	0.23370041	0.01690603755542864
uttutduoi	2	363657942789633	binhdanhocai	Trương Thủy	6273	4297	285	3992	1.5144929	0.04564713072559375
100054651049473	0	645391349250568	645391349250568	Thanh Thanh	8570	3758	722	3241	-0.13562903	0.01690603755542864

Công thức tính điểm

THUỘC TÍNH	TIÊU CHÍ ĐÁNH GIÁ	TRỌNG SỐ
total_posts	Tổng số bài viết mỗi người dùng đã đăng	0.15
total_reactions _on_posts	Tổng số lượt reactions nhận được cho tất cả bài viết của mỗi người dùng	0.25
total_comments _on_posts	Tổng số lượt bình luận nhận được cho tất cả bài viết của mỗi người dùng	0.35
total_comments _on_others_posts	Tổng số lượt bình luận trên các bài đăng của người khác	0.15
total_reactions _on_others_posts	Tổng số reactions nhận được khi bình luận trên các bài đăng của người khác	0.10

Công thức tính điểm

$$\text{influence_score} = \text{total_posts} * 0.15 + \text{total_reactions_on_posts} * 0.25 + \text{total_comments_on_posts} * 0.35 + \text{total_comments_on_others_posts} * 0.15 + \text{total_reactions_on_others_posts} * 0.10$$

Pagerank: Dùng để đánh giá mức độ tin cậy của một Website / tài liệu

$$PR(A) = (1-d) + \left(+\frac{PR(T1)}{C(T1)} + \frac{PR(T2)}{C(T2)} + \dots + \frac{PR(Tn)}{C(Tn)} \right)$$

PR(A): Pagerank của trang AA

d: hệ số giảm dần, thường là 0.85


PR(Tn): Pagerank của các trang Tn liên kết đến trang AA

C(Tn): số lượng liên kết outbound từ các Tn

04

Thực nghiệm và hướng phát triển

Mô hình thực nghiệm



Hướng phát triển

- Mở rộng đa dạng nguồn dữ liệu của ứng dụng.
- Có khả năng thu thập được dữ liệu các trang web có độ phức tạp cao.
- Tăng tốc độ và hiệu suất bằng đa luồng hoặc phân tán hoá quá trình xử lý.
- Tích hợp với Spark Connect trong việc xử lý dữ liệu lớn bằng thuật toán Pagerank.
- Phát triển giao diện người dùng.

**Trân trọng cảm ơn cô
và các bạn đã chú ý lắng nghe !**

Q&A



 BROWSE

 SCHEMA

 SECURITY

 GRAPH

 FUNCTIONS

 DB

```
1 SELECT 10 POINTS FROM MRS.NGUYEN_THI_THUY_LOAN WHERE GROUP_ID = 9
```